Random walk

Opis problemu

Poniżej przedstawiona jest implementacja algorytmu **TD(0)** do problemu **random walk**.

Diagram:

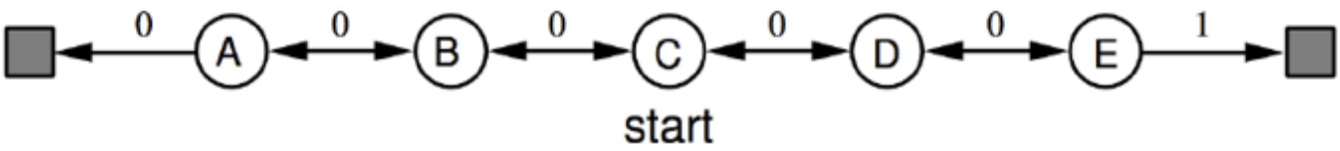

Przypomnijmy podstawowe fakty:

- **Kółkami** oznaczone są **stany nieterminalne**, **kwadratami stany terminalne**.
- Wszystkie **epizody rozpoczynają** się w środkowym stanie **C**.
- W dowolnym stanie nieterminalnym **prawdopodobieństwa ruchu w lewo i ruchu w prawo** są równe i wynoszą **0.5** (to jest polityka **pi**).
- Nad strzałkami widoczne są **wartości nagród**. Tylko przejście ze stanu **E** do **stanu terminalnego po prawej stronie** skutkuje nagrodą **R=1**. Poza tym wszystkie nagrody wynoszą **0**.

Algorytm

Implementujemy algorytm:

Tabular TD(0) for estimating v_π

Input: the policy π to be evaluated
Algorithm parameter: step size $\alpha \in (0, 1]$
Initialize $V(s)$, for all $s \in \mathcal{S}^+$, arbitrarily except that $V(terminal) = 0$

Loop for each episode:
  Initialize S
  Loop for each step of episode:
    $A \leftarrow$ action given by π for S
    Take action A, observe R, S'
    $V(S) \leftarrow V(S) + \alpha\big[R + \gamma V(S') - V(S)\big]$
    $S \leftarrow S'$
  until S is terminal

Implementacja

Zacznijmy od importu potrzebnej biblioteki:

```
import numpy as np
```

Stany oznaczamy cyframi począwszy od lewej strony:

- Stan terminalny *z lewej strony* - **0**
- Stan A - **1**
- Stan B - **2**
- Stan C - **3**
- Stan D - **4**
- Stan E - **5**
- Stan terminalny *z prawej strony* - **6**

Wartości początkowe **V** dla wszystkich stanów:

```
V = np.zeros(7)
print(V)
```

```
[0. 0. 0. 0. 0. 0. 0.]
```

```
epochs = 1000 #liczb epok czyli to ile epizodów uwzględnimy w wyliczeniu V (im więcej tym
alpha = 0.9
gamma = 0.2 #bez zdyskontowania

for i in range(epochs):
  state = 3 #stan początkowy w każdym epizodzie
```

```
  state = 3 #stan początkowy w każdym epizodzie
  while True:
    #losowanie 0 lub 1: 0 ruch w lewo, 1 ruch w prawo
    if np.random.randint(2) == 0:
      next_state = state - 1
    else:
      next_state = state + 1

    #nagroda wynosi 1 przy przejściu do stanu 6, poza tym nagroda wynosi 0
    if next_state == 6:
      R = 1
    else:
      R = 0

    #modyfikacja wartość V zgodna z TD
    V[state] = V[state] + alpha * (R + gamma*V[next_state] - V[state])

    state = next_state

    #Jeżeli dotarliśmy do stanu terminalnego - koniec epizodu
    if state == 6 or state == 0:
      break
```

Wypiszmy wyliczone wartości **V**:

```
print(V)
```

```
[0.00000000e+00 6.86317255e-10 3.43476962e-09 1.14361897e-07
 2.54094516e-02 9.13124120e-01 0.00000000e+00]
```

Wartości **teoretyczne** podane w wykładzie (**slajd 19**):

```
print([0,1/6,2/6,3/6,4/6,5/6,0])
```

```
[0, 0.16666666666666666, 0.3333333333333333, 0.5, 0.6666666666666666, 0.833333333333
```

Polecenie

Przetestuj działanie powyższego algorytmu dla **3 wybranych par wartości parametrów alpha i gamma**. Podaj wyliczone wartości **V**. Skomentuj uzyskane rezultaty.

DO UZUPEŁNIENIA

alpha=0.5 gamma=0.9

V=[0. 0.00592163 0.0771827 0.14550578 0.27124381 0.43476747

0.]

alpha=0.3 gamma=0.8

V=[0. 0.01626159 0.03699579 0.16040105 0.30423889 0.64471218 0.]

alpha=0.9 gamma=0.1

V=[0.00000000e+00 2.97608758e-10 2.03699562e-09 1.72541693e-05 8.38542879e-02 9.91080806e-01 0.00000000e+00]

Zmiana alphy i gammy ma duży wpływ na wartości V. Im większy współczynnik gamma oraz im mniejszy współczynnik alpha to wyliczone wartości zbiżają się do wartości teoretycznych. Wysoka alpha i niska gamma powoduje spadek wartości V